2026 DATA·AI 분석 경진대회

참가신청서 및 공모계획서(초안)

팀명	[작성 필요]	**대표자**	[작성 필요]
소속	[작성 필요]	**연락처**	[작성 필요]
전자우편	[작성 필요]	**팀원**	[작성 필요: 성명·소속·역할]
신청 과제	수질·수문·기상 융합 기반 댐·하천 유해남조류(녹조) 7 일 예측 AI 모델 개발	**구분**	AI 문제해결형
제출물	예측 결과 파일, 재현 가능한 분석 코드·설정, 방법론 설명	**작성일**	[작성 필요]

1. 신청 취지와 문제 정의

본 팀은 유해남조류 세포수(cells/mL)를 기준일 이후 7 일 시점에 예측하여, 취·정수장 운영자와 수질관리자가 선제적으로 대응할 수 있도록 돕는 AI 모델을 제안한다. 핵심은 단순한 농도 회귀가 아니라, 수질·수문·기상 변화가 누적되어 급증으로 이어지는 과정을 시간 순서에 맞게 반영하는 것이다.

공고의 5 개 대상 지점(해평, 강정·고령, 칠서, 물금·매리, 대청호 회남)을 공통 모델로 학습하되, 지점별 수계 특성은 station_id 임베딩/범주형 변수와 지점별 보정으로 분리한다. 예측값은 log10(cells+1) 공간에서 안정적으로 학습한 뒤 원 단위 세포수로 복원한다.

2. 제공 샘플에서 확인한 문제 특성

확인 항목	샘플 관측	모델 설계 의미
대상 변동성	조류 샘플 87 행에서 0~489,500 cells/mL	평균값 중심 모델만으로는 급증 구간을 놓칠 수 있어 로그 변환과 상승 국면 모델이 필요
목표일 간격	채점 조합 75 건 중 정확히 7 일은 51 건, 나머지는 4~10 일	관측일 자체가 불규칙하므로 base_date 와 target_date 의 실제 간격을 명시적 변수로 관리
지점 이질성	station_id 5 개 지점의 수문·기상 환경이 상이	전체 데이터의 공통 패턴과 지점별 보정을 함께 학습

위 수치는 제공된 샘플 파일을 탐색한 결과이며, 본 학습에서는 전체 제공 데이터의 결측·시점·단위를 다시 검증한 뒤 동일한 규칙으로 피처를 생성한다.

3. 제안 모델: '관측시점 인식형 수문 메모리 앙상블'

- 시점 안전 데이터셋: 기준일 시점에 실제로 알 수 있는 값만 결합한다. 미래 관측값, 목표일 이후 값, 사후 보정값은 피처에서 제외하고 데이터별 발표시점을 관리한다.
- 수문 메모리 피처: 수온·pH·전기전도도·탁도·영양염·조류 군집과 함께 강수·기온·일사량·저수량·방류량의 1/3/7/14/28 일 누적·변화율을 구성한다. 짧은 강우 충격과 체류시간에 가까운 누적 효과를 함께 포착한다.
- 두 단계 예측: (1) 7 일 내 급증 가능성/경보 초과 위험을 분류하고, (2) 정상·상승 국면별 회귀 모델을 가중 결합한다. 최종 제출은 공고 양식의 세포수 회귀값으로 제공하며, 분류 결과는 운영 해석용 보조 산출물로만 사용한다.
- 신뢰구간 동시 제공: 분위수 회귀 또는 conformal prediction 으로 예측구간을 산출해, 단일 숫자뿐 아니라 '주의가 필요한 불확실성'을 제시한다. 이는 평가 규칙을 바꾸지 않는 의사결정 보조 기능이다.
- 설명 가능한 결과: SHAP 등으로 지점·날짜별 주요 요인을 제시해, 수질관리자가 왜 위험 신호가 나왔는지 확인할 수 있게 한다.

4. 선행연구의 한계와 해결 전략

실제 연구	한계·주의점	본 팀의 보완
Song et al. (2023), 낙동강 유해남조류 ML	동일 시점 예측과 무작위 8:2 분할 중심이라, 미래 7 일 예측의 시간 일반화 성능을 과대평가할 위험이 있다.	학습은 과거로만 제한하고 2024 년을 고정 검증 연도로 둔다. 모든 lag·rolling 피처는 기준일 이전 정보만 사용한다.
Kim et al. (2023), hybrid DL	1 일보다 7·14 일 예측에서 성능이 크게 낮아졌고, 장기 예측은 관측 빈도·시간 변동성에 민감하다.	복잡한 딥러닝을 기본값으로 두지 않고, 결측 인지형 트리 앙상블을 기준선으로 한다. DL 은 2024 년 검증에서 추가 이득이 있을 때만 잔차 보정에 사용한다.
Lee et al. (2021), 저수지 조기경보	집중 모니터링 자료가 필요한 경보 중심 접근은 다른 지점·불규칙 관측에 바로 이식하기 어렵다.	세포수 회귀를 주 과제로 유지하고, 경보 위험은 회귀값·예측구간에서 파생한다. 지점별 결측 패턴과 실제 목표일 간격을 모델 입력에 포함한다.

5. 검증 및 실행 계획

평가는 공고 안내에 맞춰 2023 년까지를 학습 구간, 2024 년을 검증 구간으로 고정하고, 이후 숨김 평가 연도에 일반화되는지를 확인한다. 성능은 log10(cells+1) 기준 RMSE·MAE 와 원 단위 R^2/NSE 를 함께 보며, 단순 지속모형(직전 관측값) 및 계절 기준선보다 개선되는지 먼저 검증한다.

단계	핵심 작업	산출물
1. 데이터 점검	단위·결측·관측시점·지점 매핑 확인, 누수 방지 데이터 사전 작성	데이터 품질표·피처 명세
2. 기준선	지속모형·계절 기준선·LightGBM/CatBoost 계열 비교	고정 검증 성능표

3. 개선	수문 메모리·상승 국면·불확실성 피처를 하나씩 추가	실험 등록부·재현 설정
4. 제출	최적 고정 모델로 예측 CSV 생성, 범위·날짜·지점 검증	제출 파일·방법론 요약

6. 기대효과 및 추가 참신 아이디어

기대효과는 7 일 전 위험 신호를 수치와 불확실성으로 함께 제공하여 원수 관리, 조류경보 준비, 현장 추가 채수 우선순위 설정을 돕는 것이다. 과제의 핵심 평가지표는 세포수 예측 성능으로 유지하되, 현장 활용성을 높이는 보조 지표를 분리해 제시한다.

- 능동 관측 제안: 예측구간이 넓고 경보 초과 확률이 높은 날짜·지점을 우선 채수 후보로 표시한다. 같은 관측 예산에서 정보 가치가 큰 지점을 먼저 관측하게 하는 아이디어다.
- 반사실적 시나리오: '향후 3 일 강우량이 평년보다 높을 때'처럼 관측 가능한 기상 예보를 대입해 위험 변화 방향을 제시한다. 공식 채점용 예측과 분리하여, 운영 시나리오 기능으로 검증한다.
- 데이터 드리프트 감시: 계절·지점별 피처 분포가 학습기간과 달라지면 경고를 내고 예측 신뢰도를 낮춘다. 재학습 필요성을 조기에 알리는 안전장치다.

7. 참고문헌 및 공고 근거

1. 한국과학기술정보연구원(KISTI), 2026 DATA·AI 분석 경진대회 문제 상세: '수질·수문·기상 융합 기반 댐·하천 유해남조류(녹조) 7 일 예측 AI 모델 개발'. https://aida.kisti.re.kr/competition/main/problem/PROB_000000000004602/detail.do
2. Song, H. H. et al. (2023). A Study on the Predicting Harmful Cyanobacteria Algal Blooms Using Machine Learning Technology – The Nakdong River Case. Journal of Korean Institute of Intelligent Systems, 33(1), 29–34. https://doi.org/10.5391/JKIIS.2023.33.1.29
3. Kim, H., Shin, S., & Cha, Y. (2023). Incorporation of feature engineering and attention mechanisms into hybrid deep learning models for forecasting cyanobacterial harmful algal blooms. Journal of Cleaner Production, 414, 137564. https://doi.org/10.1016/j.jclepro.2023.137564
4. Lee, S. et al. (2021). A machine learning approach for early warning of cyanobacterial bloom outbreaks in a freshwater reservoir. Journal of Environmental Management, 288, 112415. https://doi.org/10.1016/j.jenvman.2021.112415

대표자: [작성 필요] (서명 또는 인)